

REPUBLIQUE DU SENEGAL

Peuple - But - Foi

UNIVERSITE ASSANE SECK DE ZIGUINCHOR



UFR : Science Et Technologie

DEPARTEMENT : Informatique

NIVEAU : Master 2 Génie Logiciel

MODULE : BIG DATA

**SUJET : Mise en place d'un pipeline Big Data pour
l'analyse des tendances de prix des produits
multimédia et électroménagers au Sénégal**

REDIGE PAR :

Mouhamed Ndoye

PROFESSEUR :

Madame Marie Ndiaye

ANNEE
UNIVERSITAIRE

2024-2025

Table des matières

I.	Introduction	1
II.	Web Scraping – Collecte des données	2
1.	Objectif	2
2.	Périmètre de l'étude (Sites cibles)	2
3.	Méthodologie	3
a.	Segmentation des catégories	3
b.	Technologies utilisées	3
c.	Processus d'extraction et de traitement	3
d.	Stockage temporaire	3
III.	ETL – Nettoyage et Transformation des données (Pentaho PDI)	4
1.	Vue d'ensemble du Pipeline	4
2.	Analyse détaillée des étapes du flux	4
A.	Acquisition et Filtrage Qualité	4
B.	Normalisation et Nettoyage Technique	4
C.	Enrichissement et Double Sortie	5
D.	Segmentation Métier et Exportation	5
IV.	Stockage Big Data – Apache Cassandra	6
1.	Schéma de la base de données	6
V.	Analyse avec Spark SQL	7
1.	Objectif et Méthodologie	7
2.	Résultats des Requêtes Analytiques	8
A.	Le prix moyen par produit	8
B.	Comparaison des prix par vendeur	9
C.	Statistiques par catégorie de produits	9
3.	Synthèse de l'analyse	10
VI.	Conclusion Générale et Perspectives	11
1.	Synthèse du projet	11
2.	Résultats marquants	12
3.	Perspectives	12

Liste des figures

Figure 1: une chaîne Big Data -----	1
Figure 2: Panorama des sites cibles pour l'extraction de données. -----	2
Figure 3:Flux de transformation ETL et pipeline de nettoyage des données sous Pentaho-----	5
Figure 4: Description du schéma -----	6
Figure 5: Modélisation logique et schéma de la table sous Apache Cassandra -----	7
Figure 6: Prix moyen par produit-----	8
Figure 7: Comparaison des prix et du volume de produits par vendeur -----	9
Figure 8: Statistiques par catégorie de produits -----	9
Figure 9: Comparaison du prix moyen des produits par catégorie sur le marché sénégalais -----	10
Figure 10: Comparaison du prix moyen par plateforme de e-commerce au Sénégal-----	11

I. Introduction

La fluctuation des prix des produits multimédia (smartphones, ordinateurs, télévisions, accessoires multimédia, jeux vidéo, etc.) et des produits électroménagers (réfrigérateurs, congélateurs, climatiseurs, cuisinières, machines à laver, micro-ondes, machines à café, etc.) constitue un enjeu économique important au Sénégal.

Avec la montée du commerce en ligne, de nombreux sites publient quotidiennement des informations sur les produits et leurs prix. Ces données constituent une source précieuse pour l'analyse des tendances de prix, permettant :

- ✓ de comparer les prix entre différents vendeurs,
- ✓ d'identifier les variations saisonnières ou promotionnelles,
- ✓ d'aider les consommateurs à prendre des décisions éclairées, et de fournir des insights pour les fournisseurs et distributeurs.

🚦 Objectif du projet : Construire une chaîne Big Data complète pour analyser les tendances de prix des produits multimédia et électroménagers en suivant le pipeline :

Le rapport détaillera chaque phase : collecte des données via web scraping, nettoyage et transformation avec Pentaho, stockage dans Cassandra, puis analyse avec Spark SQL.



Figure 1: une chaîne Big Data

II. Web Scraping – Collecte des données

1. Objectif

L'objectif du Web Scraping est de collecter automatiquement les informations des produits multimédia et électroménagers depuis plusieurs sites de commerce en ligne afin d'analyser leurs tendances de prix. Les données extraites incluent :

- ❖ Nom du produit
- ❖ Catégorie
- ❖ Prix
- ❖ Vendeur
- ❖ Date de collecte

2. Périmètre de l'étude (Sites cibles)

Pour ce projet, nous avons choisi quatre sites représentatifs :

N°	Site	URL
1	Jumia	https://www.jumia.sn/
2	Expat-Dakar	https://www.expat-dakar.com/multimedia
3	DakarMarket	https://dakarmarket.sn/
4	ShopMeAway	https://www.shopmeaway.com/categories/appliances

Figure 2: Panorama des sites cibles pour l'extraction de données.

3. Méthodologie

a. Segmentation des catégories

Le scraping a été ciblé sur deux segments stratégiques :

- ✓ **Multimédia** : Smartphones, Télévisions, Ordinateurs portables et accessoires.
- ✓ **Électroménager** : Réfrigérateurs, Congélateurs, Cuisinières, Machines à laver.

b. Technologies utilisées

Le développement des scripts de collecte s'est appuyé sur l'écosystème **Python**, reconnu pour sa robustesse en extraction de données :

- ✓ **Python 3.12** : Langage de programmation principal.
- ✓ **Requests** : Pour l'envoi des requêtes HTTP et la récupération du code source des pages.
- ✓ **BeautifulSoup4** : Pour le parsing (analyse) de l'arborescence DOM HTML et l'extraction des balises spécifiques.
- ✓ **CSV & JSON** : Bibliothèques pour la structuration et l'exportation des données brutes.

c. Processus d'extraction et de traitement

Le script parcourt les listes de produits en suivant une logique de pagination :

1. **Requête** : Récupération de la page via `requests.get()`.
2. **Parsing** : Identification des sélecteurs CSS ou des balises HTML (`<div>`, `<span>`, `<h1>`) contenant les informations cibles.
3. **Nettoyage primaire** : Suppression des caractères spéciaux (ex: "CFA", espaces insécables) pour préparer les champs numériques (prix).
4. **Horodatage** : Injection de la date système pour chaque ligne extraite.

d. Stockage temporaire

À l'issue de l'exécution, l'ensemble des données est consolidé dans un fichier plat : **dataset_master2_senegal_nobom.csv**. Ce fichier sert de point d'entrée unique

(Staging Area) pour la phase suivante de transformation sous **Pentaho Data Integration**.

III. ETL – Nettoyage et Transformation des données (Pentaho PDI)

1. Vue d'ensemble du Pipeline

Le flux `etl_produits_multimedia_electromenager` constitue la colonne vertébrale du projet. Il transforme un fichier CSV hétérogène en données structurées distribuées vers plusieurs cibles (Base de données et fichiers plats). Chaque étape est validée par un succès visuel (icônes vertes), garantissant l'intégrité du traitement.

2. Analyse détaillée des étapes du flux

A. Acquisition et Filtrage Qualité

- **Extraction depuis fichier CSV** : Lecture du fichier source `dataset_master2_senegal_nobom.csv` contenant les données brutes du scraping.
- **Filtrage lignes (Premier niveau)** : Séparation critique des données. Les prix hors normes ou erreurs de capture sont isolés dans le fichier `prix_rejeter`, tandis que les données valides alimentent le flux `prix_accepter`.

B. Normalisation et Nettoyage Technique

- **Altération structure flux** : Conversion des types de données (typage des prix en numérique et des dates) pour permettre les calculs statistiques.
- **Value mapper** : Standardisation des libellés (catégories et vendeurs) pour uniformiser la casse et corriger les variations textuelles.
- **Tri lignes & Dédoublement (HashSet)** : Élimination des annonces redondantes. L'algorithme HashSet garantit que chaque produit est unique pour un vendeur donné, évitant de fausser les moyennes de prix.

C. Enrichissement et Double Sortie

- **Altération structure flux 2** : Une seconde passe technique pour préparer les champs spécifiques requis par le stockage NoSQL.
- **Insertion dans produits cassandra** : Chargement des données nettoyées dans Apache Cassandra pour une persistance Big Data haute performance.

D. Segmentation Métier et Exportation

- **donnees finales** : Génération d'un fichier global consolidé de tous les produits propres.
- **Filtrage lignes 2 (Segmentation)** : Le flux est divisé selon la thématique du produit :
 - **donnees Electromanger** : Export spécifique des réfrigérateurs, cuisinières, etc.
 - **donnees Multimedia** : Export spécifique des smartphones, ordinateurs et tablettes.




Figure 3: Flux de transformation ETL et pipeline de nettoyage des données sous Pentaho

IV. Stockage Big Data – Apache Cassandra

1. Schéma de la base de données

Conformément aux objectifs de stockage, nous avons conçu un schéma optimisé pour les requêtes analytiques de prix.

- **Keyspace** : senegal_market
- **Table** : produits_collectes

Colonne	Type	Rôle	Description
nom_produit	String	Partition Key	Assure la distribution des données sur le cluster.
vendeur	String	Clustering Key	Permet de trier et filtrer les prix par boutique.
categorie_standard	String	Attribute	Catégorie parente (ex: Multimédia, Électroménager).
categorie	String	Attribute	Sous-catégorie spécifique du produit (ex: Telephone,ordinateur,etc).
prix	bigint	Attribute	Valeur numérique pour les calculs de moyennes.
date_collecte	timestamp	Attribute	Pour l'analyse temporelle des tendances.

Figure 4: Description du schéma

```
CREATE TABLE senegal_market.produits_collectes (
  vendeur text,
  nom_produit text,
  date_collecte timestamp,
  categorie text,
  categories_standard text,
  prix int,
  PRIMARY KEY (vendeur, nom_produit, date_collecte)
) WITH CLUSTERING ORDER BY (nom_produit ASC, date_collecte DESC)
AND additional_write_policy = '99p'
AND bloom_filter_fp_chance = 0.01
AND caching = {'keys': 'ALL', 'rows_per_partition': 'NONE'}
AND cdc = false
AND comment = ''
AND compaction = {'class': 'org.apache.cassandra.db.compaction.SizeTieredCompactionStrategy', 'max_threshold': '32', 'min_threshold': '4'}
AND compression = {'chunk_length_in_kb': '16', 'class': 'org.apache.cassandra.io.compress.LZ4Compressor'}
AND memtable = 'default'
AND crc_check_chance = 1.0
AND default_time_to_live = 0
AND extensions = {}
AND gc_grace_seconds = 864000
AND max_index_interval = 2048
AND memtable_flush_period_in_ms = 0
AND min_index_interval = 128
AND read_repair = 'BLOCKING'
AND speculative_retry = '99p';
cqlsh:senegal_market>
```

Figure 5: Modélisation logique et schéma de la table sous Apache Cassandra

V. Analyse avec Spark SQL

1. Objectif et Méthodologie

L'étape finale de notre pipeline Big Data consiste à exploiter les données nettoyées et stockées dans **Apache Cassandra**. L'analyse est réalisée via **Apache Spark SQL** au sein d'un environnement Jupyter Notebook (`analyse_prix.ipynb`).

Cette phase permet de transformer des données brutes en indicateurs stratégiques grâce à la puissance du calcul distribué. Le processus technique a suivi trois étapes clés :

- **Connexion** : Utilisation du connecteur Spark-Cassandra pour charger la table `produits_collectes`.
- **Préparation** : Création d'une vue temporaire nommée `produits` pour permettre l'exécution de requêtes SQL standard.

- **Calculs** : Utilisation de fonctions d'agrégation (AVG, ROUND, MIN, MAX) pour extraire les tendances du marché.

2. Résultats des Requêtes Analytiques

A. Le prix moyen par produit

Cette requête permet d'identifier les articles les plus onéreux après le filtrage des anomalies effectué par l'ETL. Les résultats montrent une cohérence totale avec le marché sénégalais actuel.

```

... +-----+-----+
|          nom_produit|prix_moyen|
+-----+-----+
|TELEVISEUR 77POUC...| 1950000.0|
|TELEVISEUR 65POUC...| 1350000.0|
|Samsung Galaxy Z ...|  890000.0|
|Bosch KGN49AIBT, ...|  832500.0|
|TV LG OLED Evo OL...|  823000.0|
|MIDEA Climatiseur...|  782500.0|
|REFRIGERATEUR SBS...|  700000.0|
|Climatiseur Hisen...|  661500.0|
|Bosch KGE398IBP -...|  621500.0|
|      Honor Magic V3|  600000.0|
|Daikin avec kit d...|  597500.0|
|Hisense RB440N4AC...|  590000.0|
|  Hp spectre X360 16|  590000.0|
|      Hp Spectre...|  590000.0|
|OLIMPIA SPLENDID ...|  586500.0|
|MacBook M1 Pro 20...|  580000.0|
|Bosch KGE39ALCA- ...|  550500.0|
|Frigo Side by Sid...|  549900.0|
|Astech Réfrigérat...|  547970.0|
|REFRIGERATEUR CLA...|  495000.0|
+-----+-----+
only showing top 20 rows

```

Figure 6: Prix moyen par produit

B. Comparaison des prix par vendeur

Cette analyse permet de positionner les sites de e-commerce les uns par rapport aux autres en fonction de la valeur de leur catalogue et de leur volume d'offres.

vendeur	prix_moyen_vendeur	nb_produits
Expat-Dakar	303848.76	49
ShopMeAway	217324.56	114
DakarMarket	122406.59	44
Jumia	119786.89	259

Figure 7: Comparaison des prix et du volume de produits par vendeur

C. Statistiques par catégorie de produits

En exploitant la segmentation, nous avons calculé les prix moyens, minimums et maximums par type d'équipement.

categorie	prix_moyen	prix_min	prix_max
Refrigerateur	223575.02	2500	832500
Climatiseur	222588.83	8400	782500
Ordinateur	199264.53	19500	590000
Television	173396.99	8000	1950000
Telephone	106775.87	3500	890000
Tablette	54582.37	800	325000

Figure 8: Statistiques par catégorie de produits

3. Synthèse de l'analyse

Les visualisations générées (Figures 9 et 10) confirment que le pipeline Big Data est opérationnel. La séparation des flux dans Pentaho a permis d'isoler les produits par catégorie, facilitant ainsi des comparaisons sectorielles précises. Ces résultats fournissent une base solide pour aider les consommateurs sénégalais à prendre des décisions éclairées en comparant les prix entre les différentes plateformes.




Figure 9: Comparaison du prix moyen des produits par catégorie sur le marché sénégalais




Figure 10: Comparaison du prix moyen par plateforme de e-commerce au Sénégal

VI. Conclusion Générale et Perspectives

1. Synthèse du projet

Ce projet a permis de concevoir et de déployer une **chaîne Big Data complète** pour l'analyse des prix du marché multimédia et électroménager au Sénégal. En suivant le pipeline imposé (**Web Scraping** → **Pentaho** → **Cassandra** → **Spark SQL**), nous avons réussi à transformer des données brutes du web en indicateurs décisionnels fiables.

Chaque étape a apporté une valeur ajoutée critique :

- **Collecte** : L'automatisation via Python a permis de constituer un échantillon représentatif de l'offre locale (Jumia, Expat-Dakar, etc.).

- **Traitement (ETL) :** Le flux Pentaho a été le garant de la qualité des données. Le filtrage rigoureux a permis d'écarter les prix aberrants, tandis que le dédoublonnage par **HashSet** a assuré l'intégrité statistique des moyennes calculées.
- **Stockage :** La modélisation sous **Apache Cassandra** a offert une structure robuste, capable de supporter une montée en charge du volume de données tout en restant optimisée pour les requêtes analytiques.
- **Analyse :** L'utilisation de **Spark SQL** a démontré la puissance du calcul distribué pour extraire des insights concrets, comme le positionnement premium d'Expat-Dakar ou la diversité de l'offre de Jumia.

2. Résultats marquants

L'analyse finale met en évidence que les catégories **Réfrigérateur** et **Climatiseur** sont les plus onéreuses, avec des prix moyens dépassant **220 000 FCFA**. À l'inverse, le secteur des **Tablettes** constitue le point d'entrée le plus accessible du segment multimédia. Ces résultats valident la capacité de notre pipeline à fournir une visibilité claire sur les disparités de prix entre les vendeurs.

3. Perspectives

Bien que fonctionnelle, cette chaîne Big Data pourrait être enrichie par :

- **L'analyse de sentiment :** Intégrer les commentaires des clients pour corréler le prix à la satisfaction.
- **Le Monitoring en temps réel :** Automatiser le déclenchement du pipeline quotidiennement pour suivre l'inflation des prix.
- **Machine Learning :** Implémenter des modèles de prédiction pour anticiper les baisses de prix lors des périodes promotionnelles (ex: Black Friday).

Ce projet démontre ainsi la pertinence des technologies Big Data pour l'analyse économique locale dans un contexte africain